

Salgsprognoser for en dagligvarekjede: en sammenligning av lineær regresjon og Random Forest Regressor

Del av LOG650 Forskningsprosjekt: Logistikk og Kunstig Intelligens



Forfatter(e): Erik Brendehaug, Joseph James, Pål Rånes, Marthe Slåtta Bjerke

Totalt antall sider inkludert forsiden: 29

Molde, Innleveringsdato: 28.05.2026



Høgskolen i Molde
Vitenskapelig høyskole i logistikk

Obligatorisk egenerklæring/gruppeerklæring

Den enkelte student er selv ansvarlig for å sette seg inn i hva som er lovlige hjelpemidler, retningslinjer for bruk av disse og regler om kildebruk.

Du/dere fyller ut erklæringen ved å klikke i ruten til høyre for den enkelte del 1–6:

Nr.	Erklæring	Avkryssing
1	Jeg/vi erklærer at min/vår besvarelse er mitt/vårt eget arbeid.	☒
2	Jeg/vi erklærer videre at denne besvarelsen:- ikke har vært brukt til annen eksamen- ikke refererer til andres arbeid uten at det er oppgitt- ikke refererer til eget tidligere arbeid uten at det er oppgitt- har alle referanser oppgitt- ikke er kopi eller duplikat	☒
3	Brudd på ovennevnte er fusk og kan medføre annullering.	☒
4	Oppgaven kan bli plagiatkontrollert i URKUND.	☒
5	Høgskolen vil behandle mistanke om fusk etter retningslinjene.	☒
6	Jeg/vi har satt oss inn i reglene for kildebruk.	☒

Personvern

Personopplysningsloven

Spørsmål	Ja	Nei
Har oppgaven vært vurdert av NSD?	☒	☒

- Hvis ja:
Referansenummer:
- Hvis nei:
Jeg/vi erklærer at oppgaven ikke omfattes av Personopplysningsloven ☒

Helseforskningsloven

Spørsmål	Ja	Nei
Har oppgaven vært til behandling hos REK?	☒	☒

- Hvis ja:
Referansenummer:

Publiseringsavtale

Felt	Verdi
Studiepoeng	15
Veileder	Bård Inge Peterson (BIP)

Fullmakt til elektronisk publisering

Spørsmål	Ja	Nei
Gjøre oppgaven tilgjengelig for elektronisk publisering	☒	☐

Spørsmål	Ja	Nei
Er oppgaven båndlagt (konfidensiell)?	☐	☒

- Hvis ja:

Spørsmål	Ja	Nei
Kan publiseres etter båndleggingsperiode	☐	☐

Dato: 28.05.2026

Antall ord

Rapportens hovedtekst (kap. 1 Innledning til og med kap. 10 Konklusjon) er på omtrent 5 300 ord. Sammendrag, abstract, forside, litteraturliste og vedlegg er holdt utenfor tellingen.

Forfattererklæring

Gruppen har i fellesskap skrevet og godkjent denne rapporten.

Sammendrag

Dagligvarehandelens driftsrisiko er direkte knyttet til kvaliteten på etterspørselsprognosene: for høye bestillinger gir svinn og bundet kapital, mens for lave gir tomme hyller og tapte inntekter. Denne rapporten undersøker hvordan multippel lineær regresjon og Random Forest Regressor kan brukes til å predikere daglig salg for 2025 i en dagligvarekjede, og hvilke faktorer som påvirker salget mest.

Analysen bygger på et datasett med 9 994 daglige salgstransaksjoner fra perioden 2022–2025. Treningsperioden 2022–2024 dekker 6 682 rader og testperioden 2025 dekker 3 312 rader, med tidsbasert splitt for å unngå datalekkasje. Modellmatrisen består av 67 features som

inkluderer rabatt, kategoriske dimensjoner som region, produktkategori og subkategori, samt sju utledede kalendervariabler. Tre modellspor evalueres på 2025: en benchmark multippel lineær regresjon, en Random Forest-baseline med standardparametere, og en tuned Random Forest der hyperparametere er valgt gjennom et rutenettsøk med 2022–2023 som søketrening og 2024 som valideringsår. Modellene sammenlignes med RMSE som primær metrikk og MAPE som sekundær metrikk, både samlet, per måned og per segment fordelt på kvartal, rabattband, region og salgsnivå.

Tuned Random Forest er den samlet beste modellen med RMSE 578,26 og MAPE 43,97 %, og vinner RMSE i elleve av tolv måneder og tretten av fjorten segmenter. Gapet til benchmark lineær er marginalt på totalnivå, og benchmark lineær er best i segmentet for høyt salgsnivå. De mest påvirkningsrike prediktorene er rabatt (11,48 %) og kalendervariablene, der kalendervariablene alene utgjør om lag 42 % av importance i topp 10. Rapporten anbefaler tuned Random Forest som standardprognose for innkjøp, lager og aggregert ressursplanlegging, benchmark lineær som forklaringsstøtte, og baseline Random Forest som kontroll mot prosentfeil i høyrabattperioder. Funnene er prediktive og ikke kausale, og gjelder innenfor dette caset.

Abstract

Operational risk in grocery retail is directly linked to forecast quality: over-ordering leads to waste and tied-up capital, while under-ordering causes stock-outs and lost revenue. This report examines how multiple linear regression and Random Forest Regressor can be used to predict daily sales for 2025 in a grocery chain, and which factors influence sales the most.

The analysis uses 9,994 daily sales transactions from 2022–2025. Training data covers 2022–2024 (6,682 rows) and test data covers 2025 (3,312 rows), with a time-based split to prevent data leakage. The model matrix contains 67 features, including discount, categorical dimensions such as region, product category and sub-category, and seven derived calendar variables. Three tracks are evaluated on 2025: a benchmark multiple linear regression, a Random Forest baseline with default parameters, and a tuned Random Forest whose hyperparameters are selected via grid search on 2022–2023 with 2024 as the validation year. RMSE is the primary metric and MAPE the secondary, both overall, by month and by segment across quarter, discount band, region and sales level.

The tuned Random Forest is the overall best model with RMSE 578.26 and MAPE 43.97 %, winning RMSE in eleven of twelve months and thirteen of fourteen segments. The gap to the benchmark linear model is marginal overall, and the benchmark linear model is the strongest in the high-sales segment. The most influential predictors are discount (11.48 %) and the calendar variables, where the calendar variables alone account for around 42 % of importance in the top ten. The report recommends the tuned Random Forest as the standard forecast for purchasing, inventory and aggregate resource planning, the benchmark linear model as explanatory support, and the Random Forest baseline as a check against percentage error during high-discount periods. The findings are predictive rather than causal and apply within this case.

Innhold

- 1 Innledning
 - 1.1 Problemstilling
 - 1.2 Delproblemer
 - 1.3 Avgrensinger
 - 1.4 Antagelser
 - 2 Litteratur
 - 3 Teori
 - 3.1 Multippel lineær regresjon
 - 3.2 Random Forest Regressor
 - 3.3 Evalueringsmetrikker
 - 3.4 Feature engineering og dataoppsett
 - 4 Casebeskrivelse
 - 4.1 Dagligvare og beslutningssituasjonen
 - 4.2 Historisk salgsutvikling
 - 4.3 Sesongmønster i salget
 - 4.4 Utfordringer dårlige prognoser medfører i bedriften
 - 5 Metode og data
 - 5.1 Metode
 - 5.2 Data
 - 5.3 Validitet, reliabilitet og etiske hensyn
 - 6 Modellering
 - 7 Resultat
 - 8 Analyse
 - 9 Diskusjon
 - 9.1 Tolkning av hovedfunn mot problemstillingen
 - 9.2 Variablenes påvirkning
 - 9.3 Teoretiske implikasjoner
 - 9.4 Praktisk nytte for Dagligvare
 - 9.5 Metodiske begrensninger
 - 9.6 Videre arbeid
 - 10 Konklusjon
 - 11 Bibliografi
 - 12 Vedlegg
-

1 Innledning

Dagligvarehandel er preget av høy variabilitet i etterspørsel. Salget svinger med sesong, kampanjer, rabatter og regionale forhold, og konsekvensene av dårlige prognoser er direkte synlige i driften: for høye bestillinger fører til svinn og bundet kapital, mens for lave bestillinger gir utsolgte varer og tapte inntekter. Behovet for mer presise etterspørselsprognoser er derfor sentralt når virksomheter skal fatte beslutninger om innkjøp, lager, kampanjer og ressursplanlegging.

Maskinlæringsbaserte metoder som Random Forest Regressor gir nye muligheter for å fange opp ikke-lineære mønstre i historiske salgsdata sammenlignet med tradisjonelle lineære tilnærminger. Dette prosjektet analyserer et dagligvarecase for perioden 2022–2025 med mål om å utvikle og evaluere prognosemodeller for salg i 2025, og å identifisere hvilke forklaringsvariabler som bærer mest prediksjonsverdi.

Tilnærmingen kombinerer multippel lineær regresjon som tolkbar benchmark med Random Forest Regressor som ikke-lineær alternativmodell. Kombinasjonen er valgt fordi den både måler hvor

langt en enkel lineær spesifikasjon kommer på dette caset, og samtidig vurderer hva som vinnes ved en mer fleksibel ensemble-modell som naturlig leverer feature importance — den rangeringen som direkte besvarer det andre delproblemet om hvilke variabler som påvirker salget mest.

Med dette som utgangspunkt formuleres problemstillingen som styrer metodevalg, analyse og tolkning videre i rapporten.

1.1 Problemstilling

Hvordan kan multippel lineær regresjon og Random Forest Regressor brukes til å forutsi salg for 2025 for en dagligvarekjede, og hvilke faktorer påvirker salget mest?

1.2 Delproblemer

Problemstillingen dekomponeres i to delproblemer som strukturerer analyse, diskusjon og konklusjon:

1. **Modellvalg og prognoseytelse.** Hvordan sammenlignes de to modellklassene på 2025-data, målt med RMSE som primær og MAPE som sekundær metrikk, både samlet, månedlig og på tvers av segmenter som kvartal, rabattband, region og salgsnivå?
2. **Variabelanalyse.** Hvilke forklaringsvariabler har størst prediksjonsverdi, og hvordan samsvarer rangeringen fra Random Forest Regressor med koeffisientene i den lineære benchmarken?

1.3 Avgrensinger

Analysen er avgrenset på følgende punkter:

1. **Prediksjon, ikke kausal analyse.** Prosjektet undersøker hvilke variabler som predikerer salget best, ikke hvorfor salget endrer seg. Kausale slutninger forutsetter eksperimentelt design og ligger utenfor prosjektets rammer.
2. **Ingen lageroptimalisering.** Rapporten dokumenterer ikke lageroptimalisering. Det krever kostnads- og volumparametere som ikke inngår i datasettet.
3. **Ingen makroøkonomiske faktorer.** Eksterne variabler som inflasjon, rente og konjunkturer er ikke inkludert. Datasettet gir ikke grunnlag for dette, og inkludering av slike variabler ville kreve egne datakilder.
4. **Én virksomhet og ett datasett.** Analysen begrenses til det tilgjengelige datasettet. Generalisering til andre virksomheter eller bransjer forutsetter eget datagrunnlag og ny validering.
5. **To modelltyper.** Modellvalget er begrenset til multippel lineær regresjon og Random Forest Regressor, i tråd med prosjektets faglige rammer og tilgjengelig treningsgrunnlag.

1.4 Antagelser

Analysen bygger på følgende eksplisitte antagelser:

1. **Representativitet.** Datasettet antas representativt for en realistisk dagligvarekjede med tanke på sesongmønstre, rabattbruk, regionfordeling og produktkategorier. *Konsekvens:* Funnene er gyldige innenfor dette caset, men ikke nødvendigvis overførbare til andre virksomheter eller reelle kjeder.
2. **Tidsmessig relevans.** Historiske mønstre fra 2022–2024 antas relevante for å predikere 2025. *Konsekvens:* Strukturelle brudd som betydelige prissjokk, atferdsendringer eller endringer i sortiment vil svekke prediksjonens gyldighet.
3. **Tilstrekkelig datakvalitet.** Datasettet antas å inneholde tilstrekkelig variasjon i nøkkeldimensjonene sesong, rabatt, region og produktkategori til å trene modellene.

Konsekvens: Datasettet kan undervurdere virkelig støy og sjeldne hendelser sammenlignet med en faktisk driftssituasjon, noe som kan gi mer optimistiske målinger enn hva som er realistisk i produksjon.

4. **Testsett som fremtidig periode.** 2025-dataene er holdt helt utenfor trening og brukes som testperiode. *Konsekvens:* Evalueringen gir et realistisk bilde av prognosekvalitet under antakelsen om at 2025 ligner de foregående årene i mønster og struktur.

2 Litteratur

I salgsprognose og etterspørselspredikering er to metodetradisjoner spesielt relevante: klassisk statistisk regresjon og ensemble-basert maskinlæring. Begge er godt dokumenterte tilnærminger til prediktiv modellering i handels- og forretningskontekster, og dagligvare- og varehandelssektoren er et aktivt anvendelsesområde i forskningslitteraturen (Fildes et al., 2022).

Multippel lineær regresjon er en veletablert statistisk metode for å predikere en kontinuerlig utfallsvariabel fra flere forklaringsvariabler, og er et naturlig referansevalg fordi den er rask å estimere og gir tolkbare koeffisienter (James et al., 2021). Metoden bygger på flere antagelser – blant annet at residualene er normalfordelte og har konstant varians (homoskedastisitet), og at det ikke er perfekt multikollinearitet mellom forklaringsvariablene – og brudd på disse svekker tolkningsvaliditeten, men ikke nødvendigvis prediksjonskraften (James et al., 2021). Regresjonsbaserte tilnærminger har også vist seg nyttige spesifikt i dagligvarekontekst: Ulrich et al. (2021) bruker distribusjonell regresjon til å predikere daglig etterspørsel i netthandel med dagligvarer, og finner at regresjonsrammeverk som modellerer hele utfallsfordelingen – ikke bare gjennomsnittet – gir bedre beslutningsstøtte for lagerstyring.

Random Forest representerer en nyere og mer fleksibel tilnærming. Breiman (2001) introduserte metoden som et ensemble av beslutningstrær der bootstrap-aggregering og tilfeldig variabeluttrekk gjør trærne mindre korrelerte, slik at gjennomsnittet over trærne reduserer variansen sammenlignet med et enkelt tre. James et al. (2021) framhever at Random Forest håndterer ikke-lineære sammenhenger og samspill mellom variabler direkte, og at metoden gir en innebygd rangering av variabelviktighet (feature importance). I sammenlignende studier av etterspørselsprognoser i varehandel inngår Random Forest ofte som referansemodell: Mitra et al. (2022) sammenligner blant annet Random Forest, gradient boosting og nevrale nett for en flerkanals varehandelskjede og finner at tre-baserte ensemble-metoder gir lavere prognosefeil enn enklere baselinjer, særlig når etterspørselsmønsteret er sammensatt. Kang (2023) sammenligner nettopp lineær regresjon, Random Forest og gradient boosting på salgsdata fra et supermarked og finner at den lineære modellen underfitter, mens de tre-baserte modellene presterer best – men med liten innbyrdes margin.

Den empiriske litteraturen gir likevel ikke ett entydig svar på hvilken modellklasse som er best. Fildes et al. (2022) oppsummerer forskning og praksis innen varehandelsprognoser og påpeker at valg av metode avhenger sterkt av dataoppløsning, hierarkisk struktur og tilgang på forklaringsvariabler, og at enkle modeller ofte er overraskende konkurransedyktige på aggregert nivå. Spiliotis et al. (2022) studerer daglig etterspørsel på enkeltprodukt-nivå (SKU) i detaljhandel og viser at maskinlæring kan overgå statistiske metoder, men at fortrinnet er betinget av dataenes egenskaper og av hvordan modellene utnytter forklaringsvariabler. Makridakis et al. (2022) rapporterer fra M5-konkurransen, som baserte seg på daglige salgsdata fra varehandel, at gradient-boostede tremodeller systematisk slo både klassiske statistiske metoder og rene lineære modeller, men at gevinsten forutsatte rik feature-engineering og store datamengder. Samtidig viser Makridakis et al. (2018) at maskinlæring ikke automatisk er overlegen: på et bredt sett tidsrekker presterte enkle statistiske metoder bedre og krevde langt mindre beregning, et resultat senere arbeid nyanserer med at maskinlæringens fortrinn vokser med datamengden. Valget av

evalueringsmetrikk påvirker også konklusjonen: RMSE og MAPE vektlegger henholdsvis absolutt og relativ feil ulikt, og MAPE er dessuten ustabil ved lave volum (Hyndman & Koehler, 2006), slik at de to målene ikke alltid peker på samme vinnermodell.

Forskningsgapet denne rapporten adresserer ligger i krysningen mellom to forhold. For det første er sammenlignende empirisk arbeid som isolerer nettopp multippel lineær regresjon mot Random Forest for daglige salgsprognoser i dagligvaresektoren fortsatt begrenset; mye av litteraturen vektlegger enten større modellpaneler (Mitra et al., 2022; Makridakis et al., 2022) eller rikere eksterne variabler (Ulrich et al., 2021; Carbonneau et al., 2008). For det andre er effekten av streng tidsbasert oppsplitting på sammenligningens utfall sjelden isolert (Cerqueira et al., 2020). Studien bidrar med en kontrollert sammenligning på ett datasett der trening, validering og test er strengt adskilt i tid, og hvor både samlede og segmentvise metrikker rapporteres.

3 Teori

Dette kapitlet gir det faglige grunnlaget for metodevalg, analyse og tolkning senere i rapporten. Notasjon: når en kolonne eller feature fra modellmatrisen refereres direkte, skrives navnet i inline kode, for eksempel `Discount`, `Region_North` eller `dayofmonth`. I Sammendrag og Abstract brukes vanlig prosa («rabatt», «discount», «kalendervariabler») for å holde oppsummeringene tilgjengelige for et bredere publikum. *Forklaringsvariabel* brukes som samlebegrep for alle input i modellene, mens *prediktor*, *signal* og *feature* opptrer som kontekstuelle synonymer der variasjonen understøtter lesbarheten.

3.1 Multippel lineær regresjon

Multippel lineær regresjon er en supervisert læringsmetode som modellerer forholdet mellom en avhengig variabel og to eller flere uavhengige forklaringsvariabler. Modellen uttrykkes som:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

der $\hat{y}$ er predikert verdi, β_0 er konstantleddet og $\beta_1, \dots, \beta_n$ er regresjonskoeffisientene som uttrykker endringen i $\hat{y}$ per enhet endring i den tilhørende forklaringsvariabelen, alt annet likt (James et al., 2021).

Koeffisientene estimeres med **Ordinary Least Squares (OLS)**, som minimerer summen av kvadrerte residualer:

$$\sum_{i=1}^n (y_i - \hat{y}_i)^2$$

For at estimatene skal være gyldige krever metoden at fem antagelser er oppfylt (James et al., 2021): (1) linearitet mellom avhengig og uavhengige variabler, (2) uavhengige residualer, (3) homoskedastisitet — konstant varians i residualene på tvers av alle prediktornivåer, (4) normalfordelte residualer, og (5) ingen perfekt **multikollinearitet** mellom forklaringsvariablene. Multikollinearitet er særlig relevant i dette prosjektet fordi one-hot-kodede dummyvariabler kan skape høy innbyrdes korrelasjon og gjøre tolkning av enkeltkoeffisienter usikker.

Konsekvensene av brudd på antagelsene er ulike og bør holdes fra hverandre. Brudd på linearitet — for eksempel en utelatt ikke-lineær sammenheng — gir systematisk skjevhet (bias) i selve prediksjonene. Heteroskedastisitet og avhengige residualer gir derimot først og fremst feilestimerte standardfeil og dermed upålitelig statistisk inferens, uten nødvendigvis å ødelegge punktprediksjonen. Multikollinearitet blåser opp variansen til koeffisientestimatene, slik at fortegn og størrelse på enkeltkoeffisienter blir ustabile selv når modellens samlede prediksjonskraft er god.

Lineær regresjon brukes her som benchmarkmodell nettopp fordi den er tolkbar — koeffisientene gir direkte innsikt i retning og størrelse av variabeleffekter — og fordi enkle modeller ofte er overraskende konkurransedyktige i varehandelsprognoser (Fildes et al., 2022). Dens prinsipielle begrensning er at den forutsetter et i hovedsak lineært og additivt mønster i dataene, slik at betingede samspill mellom variabler ikke fanges opp uten at de spesifiseres eksplisitt.

3.2 Random Forest Regressor

Random Forest er en ensemble-metode basert på et sett med beslutningstrær som samlet gir mer stabile prediksjoner enn ett enkelt tre (Breiman, 2001). Algoritmen hviler på to grunnprinsipper:

Bootstrap aggregation (bagging): Hvert tre trenes på et tilfeldig utvalg med tilbakelegging fra treningsdataene. Dermed ser hvert tre en litt annerledes versjon av datasettet, og trærne korrelerer mindre med hverandre (Breiman, 2001).

Feature randomness: Ved hver splittingsbeslutning i et tre velges kun et tilfeldig subsett av features til vurdering — ikke alle tilgjengelige variabler. Dette reduserer korrelasjon mellom trærne ytterligere og gjør ensemblet mer robust mot overfitting (Breiman, 2001).

For regresjonsoppgaver er den endelige prediksjonen gjennomsnittet av alle trærnes individuelle prediksjoner. Dette reduserer overordnet varians og demper effekten av støy i enkelttrær.

Mekanismen kan forstås gjennom **bias–variens-avveilingen**. Et enkelt, dypt beslutningstre har lav bias, men høy varians: det tilpasser seg treningsdataene tett og blir ustabilt mot små endringer i datagrunnlaget. Ved å gjennomsnitte mange avkorrelerte trær reduserer Random Forest variansen kraftig uten å øke biasen tilsvarende, slik at forventet prediksjonsfeil på nye data går ned. Fordi hvert tre trenes på et bootstrap-utvalg, kan de observasjonene som ikke inngår i utvalget (*out-of-bag*) brukes som et innebygd valideringsmål uten et separat hold-out-sett. I motsetning til lineær regresjon modellerer trærne ikke-lineære terskler og betingede samspill mellom variabler direkte, fordi hver splitt deler dataene lokalt; dette er en hovedgrunn til at tre-baserte ensembler ofte gir lavere prognosefeil enn lineære modeller når etterspørselsmønsteret er sammensatt (Mitra et al., 2022; Makridakis et al., 2022).

Feature importance beregnes som gjennomsnittlig reduksjon i MSE (Mean Decrease in Impurity) på tvers av alle trær og splittings for en gitt variabel. En variabel som konsekvent reduserer prediksjonsfeilen i mange trær, rangeres høyt (Breiman, 2001).

Modellens oppførsel styres av hyperparametere som `n_estimators` (antall trær), `max_depth` (maksimal dybde per tre), `min_samples_leaf` (minste antall observasjoner i et løvnode) og `max_features` (antall features vurdert per split). Disse tilpasses gjennom hyperparametertuning mot et valideringssett.

3.3 Evalueringsmetrikker

To metrikker brukes for å evaluere prognosemodellene i dette prosjektet.

RMSE (Root Mean Squared Error) måler den gjennomsnittlige størrelsen på prediksjonsfeilen i samme enhet som utfallsvariabelen:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

Kvadreringen medfører at store avvik vektes tyngre enn små. RMSE brukes som primær metrikk i dette prosjektet fordi absolutt presisjon — å treffe riktig salgsvolum — er det mest relevante kravet for innkjøp og lagerstyring.

MAPE (Mean Absolute Percentage Error) måler det gjennomsnittlige prosentvise avviket:

$$\text{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100$$

MAPE er skalanøytral og enklere å kommunisere, men er ustabil når faktiske verdier er nær null (divisjon mot null), og overvekter dermed observasjoner med lavt volum. Metrikken brukes som sekundær metrikk. I prognosekonkurranser som M5 erstattes MAPE ofte av skalerte feilmål nettopp for å unngå denne ustabiliteten ved lave volum (Makridakis et al., 2022).

Når RMSE og MAPE peker på ulike vinnere, skyldes det at en modell kan ha lavt absolutt avvik på store volumer (lavt RMSE) uten å treffe proporsjonalt godt på små volumer (høy MAPE). Begge metrikkene er derfor nødvendige for å forstå modelloppførselen på tvers av ulike salgsnivåer (Hyndman & Koehler, 2006).

3.4 Feature engineering og dataoppsett

Feature engineering er prosessen med å utlede nye variabler fra rådata for å gjøre mønstre tilgjengelige for modellene. I dette prosjektet er kalendervariablene `year`, `month`, `quarter`, `wee kofyear`, `dayofweek`, `dayofmonth` og `is_weekend` avledet fra den opprinnelige datovariabelen. Disse variablene fanger opp sesong-, uke- og kvartalsmønstre som ikke direkte kan leses fra en rådate (Fildes et al., 2022).

One-hot encoding konverterer kategoriske variabler — som Region, Category og Sub-Category — til binære dummyvariabler. For lineær regresjon er dette nødvendig fordi modellen krever numerisk input. Random Forest bruker her samme kodede matrise for konsistens i sammenligning (James et al., 2021).

Data leakage oppstår når variabler som ikke ville vært tilgjengelige på prediksjonstidspunktet inkluderes i modellen. I dette prosjektet er `Profit` ekskludert fordi den kun er kjent etter at salget er gjennomført.

Tidsbasert oppsplitting er valgt fremfor tilfeldig oppsplitting. Treningsdata er 2022–2024 og testdata er 2025. Tilfeldig oppsplitting ville tillate fremtidige observasjoner å inngå i treningen, noe som gir kunstig god ytelse og ikke reflekterer reell prediksjon fremover i tid; tidsbasert evaluering anbefales nettopp for å unngå slike for optimistiske ytelsesestimer (Cerqueira et al., 2020). I hyperparametertuningen av Random Forest brukes 2024 i tillegg som intern valideringsperiode, mens lineær regresjon beholdes med det fulle treningsgrunnlaget.


4 Casebeskrivelse

4.1 Dagligvare og beslutningssituasjonen


Dagligvare er en dagligvarekjede som opererer på tvers av fem regioner: West, East, Central, South og North. Kjeden fører syv produktkategorier – Snacks, Eggs/Meat/Fish, Fruits & Veggies, Bakery, Beverages, Food Grains og Oil & Masala – fordelt på 23 subkategorier. Datasettet som danner analysegrunnlaget inneholder 9 994 daglige salgstransaksjoner fra perioden 2022–2025, fordelt på 24 byer.

Dagligvares operative planlegging er avhengig av pålitelige etterspørselsprognoser. Salget varierer med sesong, rabatter og regionale forhold, og konsekvensene av dårlige prognoser er direkte synlige i driften: for høye bestillinger gir svinn og bundet kapital, mens for lave bestillinger fører til utsolgte varer og tapte inntekter. Behovet for mer presise prognoser er dermed sentralt for innkjøp, lager, kampanjevurdering og ressursplanlegging.

Figur 4.1 viser gjennomsnittlig salgsnivå per produktkategori. Eggs, Meat & Fish skiller seg ut med det høyeste gjennomsnittlige salgsnivået i datasettet.



Figur 4.1 Gjennomsnittlig salgsnivå per produktkategori.



Figur 4.2 Daglig salg over perioden 2022–2025, med treningsperiode (2022–2024) og testperiode (2025) vist.

4.2 Historisk salgsutvikling

Gjennomsnittlig daglig salg for hele perioden 2022–2025 er 1 497 med et spenn fra 500 til 2 500 og standardavvik på 578. Salgsnivået er stabilt over tid: gjennomsnittsnivået i treningsperioden 2022–2024 er 1 493, mot 1 503 i testperioden 2025. Ingen tydelig veksttrend er synlig i perioden – nivået holder seg relativt konstant med lokal variabilitet.

Figur 4.2 viser salgsforløpet over tid med trenings- og testperioden markert.


4.3 Sesongmønster i salget

Månedsmønsteret viser at oktober er måneden med det høyeste gjennomsnittlige salgsnivået, mens juni er den svakeste måneden. Mønsteret er konsistent mellom trenings- og testperioden, noe som tyder på et stabilt sesongmønster i datasettet. Fjerde kvartal fremstår samlet som den sterkeste perioden, mens andre og tredje kvartal er relativt svakere.

Figur 4.3 viser gjennomsnittlig salg per måned for henholdsvis trenings- og testperioden.

4.4 Utfordringer dårlige prognoser medfører i bedriften

For Dagligvare forsterkes planleggingsrisikoen av et sortiment som spenner fra ferske varer med kort holdbarhet til tørrvarer med lengre holdbarhetsperiode. Overskuddsbestillinger fører til



Figur 4.3 Gjennomsnittlig daglig salg per måned for treningsperioden (2022–2024) og testperioden (2025).

direkte svinn og bundet kapital – konsekvenser som er særlig kostbare i kategorier som Eggs, Meat & Fish og Fruits & Veggies. Underestimering gir tomme hyller, tapte inntekter og risiko for å svekke kundelojaliteten.

Sesongvariasjonen i Figur 4.3 viser at salget svinger markant gjennom året – med topp i oktober og bunnpunkt i juni. Kombinert med rabattavhengighet gjør dette at enkle tommelfingerregler for innkjøp gir dårlige resultater i perioder med høy kampanjeaktivitet eller sesongtopper.

Nøyaktige etterspørselsprognoser for 2025 kan gi Dagligvare et bedre grunnlag for innkjøpsplanlegging og lagerstyring, støtte vurderingen av kampanjeeffekter og bidra til mer presis ressursplanlegging i perioder med høy og lav etterspørsel.


5 Metode og data

5.1 Metode

Prosjektet er en kvantitativ, prediktiv studie der historiske salgsdata fra én dagligvarekjede brukes til å bygge og evaluere prognosemodeller. Datagrunnlaget er ikke samlet inn, men stilt til disposisjon som en del av prosjektets faglige rammer. Problemstillingen besvares gjennom en trinnvis analytisk prosess: datasettet ble renset og gjort klart for modellering, deretter ble relevante variabler valgt og nye kalendervariabler utledet, og til slutt ble datasettet delt i en treningsperiode og en testperiode basert på tid.

Lineær regresjon ble valgt som benchmark-modell fordi metoden er tolkbar og gir et stabilt sammenligningsgrunnlag. Random Forest Regressor ble valgt som alternativmodell fordi den kan fange opp ikke-lineære mønstre og gir en naturlig rangering av variablenes prediksjonsverdi. Random Forest ble i tillegg tunet ved å trene på 2022–2023 og validere på 2024, slik at hyperparametere ble valgt uten å bruke testdataene. Alle tre modellspor – lineær regresjon, Random Forest baseline og tuned Random Forest – ble evaluert på 2025-data.

Evalueringen benytter RMSE som primær metrikk fordi absolutt presisjon er mest relevant for innkjøp og lagerstyring, og MAPE som sekundær metrikk for å gi et relativt bilde av prognosefeilen (se kap. 3.3). Modellene sammenlignes samlet for hele 2025 og per måned, og resultatene tolkes videre etter kvartal, rabattnivå, region og salgsnivå for å gi praktisk beslutningsstøtte til Dagligvare.



Figur 5.1 Fordeling av datatyper i rådatasettet. Fordelingen viser hvor mange kolonner som er numeriske, kategoriske og datobaserte, og underbygger valg av forbehandling og feature engineering.

5.2 Data

Datagrunnlaget er filen `Dagligvare_Dataset.csv`, som inneholder 9 994 daglige salgstransaksjoner fra en dagligvarekjede. Rådata dekker opprinnelig perioden 2015–2018 og er remappet med en syvårig kalenderforskyvning til prosjektperioden 2022–2025. Datasettet har 11 råkolonner og ingen manglende verdier eller dubletter. To ulike datoformater i kildedata – 4 042 rader med `dd-mm-yyyy` og 5 952 rader med `mm/dd/yyyy` – ble standardisert til ISO-format under rensingen.

Figur 5.1 viser fordelingen av datatyper i rådatasettet og underbygger valget av forbehandling og feature engineering.

Målvariabelen er **Sales** (heltall, spenn 500–2 500). Forklaringsvariablene som inngår i modellene er **Discount** (desimaltall, 0,10–0,35) og de kategoriske variablene **Category**, **SubCategory**, **City** og **Region**. Fra **OrderDate** er det i tillegg utledet sju kalendervariabler: **year**, **month**, **quarter**, **weekofyear**, **dayofweek**, **dayofmonth** og **is_weekend**. Fire variabler ble ekskludert: **Profit** fordi den er en lekkasjevariabel som kun er kjent etter gjennomført salg, **State** fordi kolonnen er konstant i datasettet, og **OrderID** og **CustomerName** fordi de ikke har generaliserbar prediksjonsverdi. Kategoriske variabler ble one-hot-encoded til binære dummyvariabler, slik at den endelige modellmatrisen inneholder 67 features.

Tabell 5.1 oppsummerer de 11 kolonnene i rådatasettet med datatype, manglende andel og anbefaling for videre bruk.

Tabell 5.1 Variabeloversikt med datatype, manglende andel og anbefaling for videre bruk.

Variabel	Datatype	Manglende %	Unike	Anbefaling	Begrunnelse
Sales	int64	0,0	1 989	target	Målvariabel for prognose.
Category	str	0,0	7	inkluder	Kategorisk variabel med håndterbar kardinalitet.

Variabel	Datatype	Manglende %	Unike	Anbefaling	Begrunnelse
City	str	0,0	24	inkluder	Kategorisk variabel med håndterbar kardinalitet.
Discount	float64	0,0	26	inkluder	Numerisk variabel egner seg direkte for modellering.
Region	str	0,0	5	inkluder	Kategorisk variabel med håndterbar kardinalitet.
State	str	0,0	1	ekskluder	Kolonnen er konstant i datasettet og gir ingen forklaringskraft.
Sub Category	str	0,0	23	inkluder	Kategorisk variabel med håndterbar kardinalitet.
Order Date	str	0,0	1 236	vurder	Middels/høy kardinalitet, vurder koding og nytte.
Profit	float64	0,0	8 380	vurder	Kan være informativ, men bør sjekkes for lekkasje før modellering.
Customer Name	str	0,0	50	ekskluder	Navn-kolonne har høy kardinalitet og høy risiko for overtilpasning.
Order ID	str	0,0	9 994	ekskluder	ID-variabel gir vanligvis lite generaliserbar prediksjonsverdi.

Tabell 5.2 dokumenterer feature engineering-oppsettet: hvilke input-kolonner som beholdes, transformeres eller ekskluderes, og hvilke output-kolonner de gir.

Tabell 5.2 Feature engineering-oppsett: input-kolonne, handling og resulterende output-kolonne med begrunnelse.


Input-kolonne	Handling	Output-kolonne	Begrunnelse
Sales	behold	Sales	Målvariabel for prognose.
Discount	behold	Discount	Numerisk forklaringsvariabel.
Category	behold	Category	Kategorisk feature med håndterbar kardinalitet.

Input-kolonne	Handling	Output-kolonne	Begrunnelse
Sub Category	behold	Sub Category	Kategorisk feature med håndterbar kardinalitet.
City	behold	City	Kategorisk feature med håndterbar kardinalitet.
Region	behold	Region	Kategorisk feature med håndterbar kardinalitet.
Order Date	behold	Order Date	Beholdes for sporbarhet og tidsbasert splitt.
Order Date	transformer	year	Utledet kalenderår etter remapping.
Order Date	transformer	month	Utledet måned.
Order Date	transformer	quarter	Utledet kvartal.
Order Date	transformer	weekofyear	Utledet uke i året.
Order Date	transformer	dayofweek	Utledet ukedag.
Order Date	transformer	dayofmonth	Utledet dag i måneden.
Order Date	transformer	is_weekend	Indikator for helg.
Order ID	ekskluder	–	ID-kolonne uten generaliserbar prediksjon sverdi.
Customer Name	ekskluder	–	Navn-kolonne med høy risiko for overtilpasning.
Profit	ekskluder	–	Ekskludert som potensiell lekkasjevariabel.
State	ekskluder	–	Kolonnen er konstant i datasettet og gir ingen forklaringskraft.

Tabell 5.3 dokumenterer datarensingen fra 9 994 rader inn til 9 994 rader ut, uten at rader ble fjernet eller manglende verdier oppdaget.

Tabell 5.3 Datarensing – målepunkter, verdier og kommentarer som dokumenterer kvalitetskontrollen før modellering.

Målepunkt	Verdi	Kommentar
antall_rader_inn	9 994	Observasjoner i rådata
antall_kolonner_inn	11	Variabler i rådata
manglende_verdier_inn	0	Totalt manglende i rådata
dubletter_inn	0	Eksakte dubletter i rådata
datoformat_dd_mm_yyyy	4 042	Tolket fra verdier med bindestrek
datoformat_mm_dd_yyyy	5 952	Tolket fra verdier med skråstrek
datoformat_annet	0	Verdier uten kjent mønster
ugyldige_datoer_etter_tolkning	0	Datoer som ikke lot seg parse
opprinnelig_periode_start	2015-01-02	Tidligste dato i original dataserie
opprinnelig_periode_slutt	2018-12-30	Siste dato i original dataserie
år_forskyvning	7	Kalenderforskyvning brukt for prosjektets arbeidsgrunnlag
prosjekt_periode_start	2022-01-02	Tidligste dato etter remapping
prosjekt_periode_slutt	2025-12-30	Siste dato etter remapping
rader_fjernet_manglende_kritisk_felt	0	Rader fjernet etter kontroll av dato og numeriske nøkkelfelt
dubletter_fjernet	0	Fjernet etter standardisering



Figur 5.2 Fordeling av daglige salgsverdier i trenings- og testperioden. Overlappet i fordelingene tyder på at målvariabelen er stabil mellom periodene.

Målepunkt	Verdi	Kommentar
antall_rader_ut	9 994	Observasjoner i renset datasett
manglende_verdier_ut	0	Totalt manglende etter rens
dubletter_ut	0	Eksakte dubletter etter rens

Fordelingen av kategoriske variabler viser at West-regionen utgjør 32 % av observasjonene, East 28 %, Central 23 % og South 16 %. North-regionen er representert med bare én observasjon og benyttes ikke som separat analysesegment. Produktkategoriene er jevnt fordelt med mellom 14 og 15 % av observasjonene hver, noe som betyr at ingen enkelt kategori dominerer datasettet.

Datasettet er delt tidsmessig slik at treningsdata dekker 2022–2024 og testdata dekker 2025. Tilfeldig splitt ble ikke brukt, fordi det ville tillate fremtidige observasjoner å inngå i treningen og dermed gi kunstig god ytelse. Det gjennomsnittlige salgsnivået er stabilt mellom periodene (1 493 i treningsdata og 1 503 i testdata), noe som styrker antakelsen om at historiske mønstre er overførbare til 2025. Figur 5.2 viser fordelingen av daglige salgsverdier i trenings- og testperioden.

Tabell 5.4 oppsummerer antallsfordelingen mellom trenings- og testperioden.

Tabell 5.4 Fordeling av trenings- og testdata etter tidsmessig splitt.

Delmengde	År	Antall rader	Andel
Treningsdata	2022–2024	6 682	~67 %
Testdata	2025	3 312	~33 %

5.3 Validitet, reliabilitet og etiske hensyn

Validitet. Intern validitet styrkes gjennom tidsbasert oppsplitting (2022–2024 trening, 2025 test) som hindrer datalekkasje, og gjennom adskilt valideringsperiode (2024) for hyperparametertuning av Random Forest. Ekstern validitet er begrenset av at studien bygger på ett datasett fra én virksomhet, og generalisering til reelle dagligvarekjeder krever ny validering (jf. §1.3 og §9.5).

Reliabilitet. Analysen er organisert som aktivitetsbaserte skript under 006analysis/ med faste seeds for Random Forest og uten ad-hoc-manipulering av treningsgrunnlaget mellom aktiviteter. Pipeline fra rådata til endelige metrikker er reproducerbar.

Etiske hensyn. Datasettet inneholder ingen personopplysninger eller annen sensitiv informasjon. Studien reiser dermed ikke personvern- eller forskningsetiske problemstillinger. Bruken av kunstig

intelligens som verktøy i analyse- og rapportarbeidet er åpen og dokumentert i prosjektets endringslogg og obligatoriske egenerklæring.

6 Modelling

Prosjektet evaluerer tre modellspor for å predikere daglig salg i 2025. Benchmark-modellen er en multipl lineær regresjon som gir et tolkbart sammenligningsgrunnlag. Random Forest inngår i to varianter: en baseline med standardparametere som viser hva en utuned ensemble-modell leverer på det samme datagrunnlaget, og en tuned variant der hyperparametere er valgt gjennom et strukturert søk. Sammenstillingen gir både et grunnlag for å måle gevinsten av tuning og et tolkbart referansepunkt som er robust mot overfitting.

Tabell 6.1 oppsummerer de tre modellsporene med antall features, treningsrader, sentrale hyperparametre og rolle i prosjektet.

Tabell 6.1 Oversikt over de tre modellsporene: antall features, treningsrader, sentrale hyperparametre og rolle i prosjektet.

Modellrolle	Algoritme	Treningsrader	Features	Sentrale hyperparametre	Rolle i prosjektet
benchmark lineær	LinearRegression	6 682	67	<code>fit_intercept=True</code> , ingen regularisering	Tolkbar benchmark med eksplisitt koeffisienttrenning.
baseline RF	RandomForestRegressor	6 682	67	<code>n_estimators=200</code> , <code>max_depth=None</code> , <code>min_samples_leaf=1</code> , <code>max_features=1.0</code>	RF-referanse uten tuning, for stabilitetssjekk mot tunet modell.
tuned RF	RandomForestRegressor	6 682	67	<code>n_estimators=400</code> , <code>max_depth=10</code> , <code>min_samples_leaf=4</code> , <code>max_features="sqrt"</code>	Anbefalt operativ modell etter tuning på 2024-validering.

Den multiple lineære regresjonen trenes som `LinearRegression` med `fit_intercept=True` og uten regularisering eller skalering. Modellen estimeres med OLS (se kap. 3.1) på 6 682 rader og 67 features – det vil si alle kalendervariabler, `Discount` og de one-hot-kodede kategoriske variablene. Estimert konstantledd er $-3193,55$. Modellen er tolkbar gjennom sine koeffisienter, men forutsetter at salget kan beskrives som en lineær kombinasjon av forklaringsvariablene, og den har ingen mekanisme for å fange opp interaksjoner eller ikke-lineære effekter utover de som eksplisitt er kodet inn.

Random Forest Regressor trenes på samme treningsmatrise. Baselinen bruker standardkonfigurasjonen `n_estimators=200`, `max_depth=None`, `min_samples_leaf=1`, `max_features=1.0` (dvs. at alle 67 features vurderes ved hver split), `bootstrap=True` og `random_state=42`, jf. bagging og feature randomness i kap. 3.2. Den tuned varianten bygger på et rutenettsøk der hver kandidat trenes på 2022–2023 (4 095 rader) og valideres på 2024 (2 587 rader). 2025-data inngår ikke i modellutvelgelsen – denne tidsmessige isolasjonen forhindrer datalekkasje mellom tuning og evaluering (jf. kap. 3.4 og 5.2). Vinnerkonfigurasjonen ble `n_estimators=400`, `max_depth=10`, `min_samples_leaf=4` og `max_features='sqrt'` (som gir $\lfloor \sqrt{67} \rfloor = 8$ features per split), valgt

med validerings-RMSE som primærkriterium. Vinnerkandidaten oppnådde validerings-RMSE 577,27 og validerings-MAPE 43,56%, mot baseline-kandidatens 590,30 og 44,22% på samme valideringssett. Den tunede modellen retrenes deretter på hele treningsperioden (2022–2024) før evaluering på 2025. Alle tre modellene genererer prognoser på testperioden 2025 (3 312 rader), og det er disse prognosene som danner grunnlaget for analyse og resultat i de neste kapitlene.

Tabell 6.2 viser de fem beste parameterkombinasjonene fra rutenettsøket, sortert etter RMSE på 2024-valideringen og med delta mot baseline-kandidaten.

Tabell 6.2 Topp 5 parameterkombinasjoner fra tuning av Random Forest, sortert etter RMSE på 2024-valideringen.

Kandidat	n_estimato rs	max_depth	min_sampl es_leaf	max_featu res	RMSE validering	MAPE validering (%)	Delta RMSE vs. baseline
rf_tune_30 (vinner)	400	10	4	sqrt	577,27	43,56	−13,04
rf_tune_28	400	10	2	sqrt	577,29	43,57	−13,02
rf_tune_10	200	10	2	sqrt	577,36	43,58	−12,94
rf_tune_26	400	10	1	sqrt	577,65	43,60	−12,65
rf_tune_12	200	10	4	sqrt	577,81	43,61	−12,50

7 Resultat

Tabell 7.1 oppsummerer den samlede ytelsen på 2025 for de tre modellsporene. Tuned Random Forest har lavest RMSE og MAPE, mens baseline Random Forest er svakest på RMSE og benchmark lineær er svakest på MAPE.

Tabell 7.1 Samlet prognoseytelse på 2025 (3 312 observasjoner).


Modell	RMSE	MAPE
Benchmark lineær	580,39	44,18 %
Baseline Random Forest	589,28	44,12 %
Tuned Random Forest	578,26	43,97 %

Figur 7.1 visualiserer den samlede ytelsen per modell.

Tabell 7.2 viser hvor mange av de tolv månedene i 2025 hver modell vinner på henholdsvis RMSE og MAPE.

Tabell 7.2 Månedlig vinnertelling per metrikk i 2025.

Modell	RMSE-vinner (av 12)	MAPE-vinner (av 12)
Benchmark lineær	1	3
Baseline Random Forest	0	6
Tuned Random Forest	11	3




Figur 7.1 Samlet RMSE og MAPE for benchmark lineær, Random Forest baseline og tuned Random Forest i 2025. Tuned Random Forest har lavest RMSE, mens MAPE er tettere fordelt mellom modellene.


Tabell 7.3 viser de ti variablene med høyest feature importance i den tuned Random Forest-modellen, gruppert etter variabelgruppe.

Tabell 7.3 Topp 10 feature importance for tuned Random Forest.

Rang	Variabel	Gruppe	Importance
1	Discount	Pris/kampanje	11,48 %
2	dayofmonth	Kalender	11,35 %
3	weekofyear	Kalender	10,40 %
4	month	Kalender	6,74 %
5	dayofweek	Kalender	6,52 %
6	year	Kalender	4,02 %
7	quarter	Kalender	2,95 %
8	Region_East	Region	2,04 %
9	Region_West	Region	1,91 %
10	Region_Central	Region	1,84 %



Figur 7.2 Topp 10 feature importance for tuned Random Forest. Variablene er rangert etter normalisert viktighet og viser hvilke signaler modellen faktisk vektlegger.



Figur 7.3 Samlet feature importance per variabelgruppe i topp 10 for tuned Random Forest. Figuren oppsummerer hvilke grupper av signaler (kalender, pris/kampanje, region) som dominerer modellens prediksjon.

Figur 7.2 visualiserer topp 10-rangeringen som horisontalt søyleplot.

Figur 7.3 aggregerer samme topp 10 etter variabelgruppe og viser hvilke typer signaler som dominerer prediksjonen.

Tabell 7.4 oppsummerer vinnermodellen per segment på RMSE og MAPE, fordelt på kvartal, rabattband, region og salgsnivå.

Tabell 7.4 Vinnermodell per segment på RMSE og MAPE.

Segmentdimensjon	Verdi	RMSE-vinner	MAPE-vinner
Kvartal	Q1	Tuned RF	Benchmark lineær
Kvartal	Q2	Tuned RF	Baseline RF
Kvartal	Q3	Tuned RF	Tuned RF
Kvartal	Q4	Tuned RF	Benchmark lineær
Rabatt	Lav	Tuned RF	Tuned RF
Rabatt	Middels	Tuned RF	Tuned RF
Rabatt	Høy	Tuned RF	Baseline RF
Region	Central	Tuned RF	Benchmark lineær
Region	East	Tuned RF	Tuned RF
Region	South	Tuned RF	Tuned RF
Region	West	Tuned RF	Baseline RF
Salgsnivå	Lavt salg	Tuned RF	Baseline RF
Salgsnivå	Middels salg	Tuned RF	Tuned RF
Salgsnivå	Høyt salg	Benchmark lineær	Benchmark lineær


8 Analyse

Samlet for 2025 leverer den tunede Random Forest-modellen både lavest RMSE og lavest MAPE (jf. Tabell 7.1), marginalt foran benchmark lineær og tydeligere foran baseline Random Forest. Gapet mellom modellene er lite i absolutt forstand – tuned Random Forest forbedrer RMSE med omtrent 11 enheter sammenlignet med baseline Random Forest og 2 enheter sammenlignet med benchmark lineær. Tuningeffekten tolkes som en kombinasjon av dybdebegrensningen (`max_depth=10`) og redusert `max_features`, som demper variansen i de enkelte trærne og gir mer stabile ensemble-prediksjoner på nye data (jf. kap. 3.2).

Månedsnivået nyanserer bildet vesentlig (jf. Tabell 8.1). Tuned Random Forest vinner RMSE i 11 av 12 måneder, men vinner MAPE i bare 3 måneder. Baseline Random Forest vinner ikke en eneste måned på RMSE, men vinner MAPE i 6 av 12 måneder. RMSE og MAPE peker på samme vinner bare i juli og september. Mønsteret kan forklares med at absolutt feil og prosentfeil vektet observasjoner ulikt: RMSE straffer store avvik hardt og favoriserer dermed modellen som er mest treffsikker på de største salgsmålene, mens MAPE er mer sensitiv i måneder med mange lavvolumrader der små avvik gir utslag i høye prosenttall.

Tabell 8.1 viser eksakte månedlige RMSE- og MAPE-verdier per modell, med RMSE og MAPE gruppert under hver modell.

Måned	Benchmark lineær	
	RMSE	MAPE (%)
2025-01	586,09	46,62
2025-02	577,96	42,50
2025-03	552,52	42,14
2025-04	581,28	44,76
2025-05	591,70	45,46
2025-06	560,16	43,81
2025-07	569,61	42,90
2025-08	586,60	42,19
2025-09	582,61	42,41



Figur 8.1 Månedlig bias per modell i 2025. Positive verdier betyr at modellen overestimerer salget, negative at den underestimerer. Kurven viser at alle tre modellene underestimerer i august–september.

Måned	Benchmark lineær	
	RMSE	MAPE (%)
2025-10	593,34	43,96
2025-11	597,86	47,87
2025-12	577,66	45,10

Tabell 8.1 Månedlig RMSE og MAPE per modell i 2025.


Bias-analysen av den tunede modellen viser et systematisk sesongavvik. August og september er underestimerte med henholdsvis $-5,22\%$ ($-20\,548$ salgsenheter) og $-2,77\%$ ($-16\,334$ salgsenheter), mens november og desember er lett overestimerte med $+1,05\%$ og $+2,36\%$. En mulig forklaring er at kalenderfeaturene ikke fullt ut fanger en høstoppgang som skiller seg fra tidligere år – antakelsen er at treningsperioden (2022–2024) inneholder en annen august–september-profil enn 2025, og at modellen dermed glatter ut det virkelige nivået i disse månedene. Mønsteret er konsistent på tvers av alle tre modellsporene og peker på en begrensning i det tilgjengelige sesongsignalet, ikke bare på den tunede modellen.

Bias-mønsteret kan ha flere mulige årsaker. Den mest sannsynlige er at sesongsignalet i kalendervariablene (`month`, `weekofyear`, `dayofweek`) ikke fanger en høstoppgang som er sterkere i 2025 enn i treningsårene 2022–2024 — med tre treningsår er rommet for å lære årlige avvik i samme måned begrenset. En sekundær forklaring er at modellene mangler kampanje- eller eventvariabler utover `Discount`: dersom august–september i datasettet inneholder etterspørselshendelser uten direkte rabattuttrykk, ville disse vises som systematisk underestimering uten å være modellerbare med tilgjengelige features. En tredje, mer teknisk forklaring er at gjennomsnittsegenskapen i Random Forest trekker prediksjonene mot sentrum av treningsperioden i måneder der 2025-nivået ligger over historisk gjennomsnitt.

Figur 8.1 illustrerer den månedlige biasen per modell.

Figur 8.2 viser samme månedsforløp som Tabell 8.1, men med RMSE visualisert som linjediagram.

Segmentanalysen (jf. Tabell 8.2) forsterker forskjellen mellom de to metrikkene. Tuned Random Forest vinner RMSE i 13 av 14 tolkningssegmenter – alle fire kvartaler, alle tre rabattband, alle fire regioner og to av tre salgsnivå – men må vike for benchmark lineær og baseline Random Forest i flere av MAPE-segmentene, særlig i høyrabattsegmentet, vest-regionen og lavvolumssegmentet. I segmentet «høyt salg» er benchmark lineær best på begge metrikker (RMSE 699,10, MAPE



Figur 8.2 Månedlig RMSE per modell i 2025. Tuned Random Forest har lavest RMSE i majoriteten av månedene, mens benchmark lineær slår gjennom i enkeltmåned.

30,31%), mens tuned Random Forest likevel gir lavest RMSE i segmentet «lavt salg» til tross for at tuned Random Forest-MAPE i samme segment ligger på 90,27 %.

Tabell 8.2 gir detaljert RMSE og MAPE per modell for alle 14 tolkningssegmentene, med RMSE og MAPE gruppert under hver modell.

Dimensjon	Verdi	Benchmark lineær	
		RMSE	MAPE (%)
Kvartal	1	570,43	43,58
Kvartal	2	578,10	44,69
Kvartal	3	580,18	42,48
Kvartal	4	589,94	45,85
Rabattbånd	lav	583,01	46,66
Rabattbånd	middels	577,89	44,51
Rabattbånd	høy	581,41	42,76
Region	Central	585,83	44,36
Region	East	579,39	44,19
Region	South	587,59	45,48
Region	West	573,90	43,44
Salgsbånd	lavt salg	695,06	90,79
Salgsbånd	middels salg	196,79	11,40
Salgsbånd	høyt salg	699,10	30,31

Tabell 8.2 RMSE og MAPE per modell i utvalgte segmenter (kvartal, rabattbånd, region, salgsbånd).

Feature importance (jf. Tabell 7.3) støtter tolkningen av hvilke dimensjoner som driver variasjonen: kalendervariablene utgjør samlet $\sim 42\%$ av importance i topp 10, **Discount** er sterkeste enkeltvariabel med 11,48%, og regionvariablene bidrar med $\sim 5,8\%$. Den lineære modellen gir negativt fortegn på **Discount** (koeffisient $-166,35$), mens Random Forest rangerer samme variabel øverst. Forskjellen tolkes som et mulig tegn på en ikke-lineær eller interaktiv sammenheng mellom rabatt og salg som en lineær spesifikkasjon ikke klarer å fange opp.

9 Diskusjon

9.1 Tolkning av hovedfunn mot problemstillingen

Problemstillingen spør hvordan multippel lineær regresjon og Random Forest Regressor kan brukes til å predikere salg i 2025, og hvilke faktorer som påvirker salget mest. Resultatene gir et differensiert svar. Tuned Random Forest er samlet best i 2025 med RMSE 578,26 og MAPE 43,97%, men gapet til benchmark lineær er marginalt på totalnivå – 2,13 enheter lavere RMSE og 0,21 prosentpoeng lavere MAPE. Den samlede ytelsen underslår dermed et tydeligere månedsbilde: tuned Random Forest vinner RMSE i elleve av tolv måneder, men bare tre måneder på MAPE, mens baseline Random Forest vinner MAPE i seks måneder uten å vinne RMSE en eneste måned. Det betyr at «best samlet» i praksis handler om absolutt presisjon i måneder med store salgsvolumer, mens prosentfeilen fortsatt er heterogen på tvers av året.

Bias-mønsteret nyanserer dette ytterligere. Tuned Random Forest underestimerer systematisk i august og september (henholdsvis $-5,22\%$ og $-2,77\%$) og overestimerer svakt i november og desember ($+1,05\%$ og $+2,36\%$). Mønsteret er konsistent for alle tre modellsporene, noe som peker på en begrensning i sesongsignalet i datagrunnlaget snarere enn i den enkelte modellen. Samtidig viser segmentanalysen at benchmark lineær er bedre enn tuned Random Forest i segmentet for høyt salgsnivå på både RMSE og MAPE. Det første delproblemet bør derfor besvares med en differensiert anbefaling: tuned Random Forest er mest hensiktsmessig som hovedmodell når absolutt prognosepresisjon prioriteres, mens benchmark lineær bør brukes som supplement i toppbelastningssituasjoner og som forklaringsstøtte.

Tabell 9.1 sammenstiller modellprofilene og tydeliggjør differensieringen.

Modellrolle	Samlet 2025	
	RMSE	MAPE (%)
benchmark lineær	580,39	44,18
baseline RF	589,28	44,12
tuned RF	578,26	43,97

Tabell 9.1 Modellprofil med samlet RMSE/MAPE, antall vinnermåneder og -segmenter, tolkbarhetsnivå samt hovedstyrke og hovedsvakheter per modell.

9.2 Variablenes påvirkning

Det andre delproblemet gjelder hvilke faktorer som påvirker salget mest. Rangeringen av feature importance i tuned Random Forest viser at rabatt og kalendervariabler dominerer bildet. **Discount** er det sterkeste enkeltsignalet med 11,48%, tett fulgt av kalendervariablene **dayofmonth** (11,35%), **weekofyear** (10,40%), **month** (6,74%) og **dayofweek** (6,52%). Kalendergruppen står samlet for om lag 42% av importance i topp 10, mens regionvariablene bidrar med 5,8%. De ni øverste variablene i tuned Random Forest gjenfinnes også i topp 10 for baseline Random Forest, noe som styrker stabiliteten i rangeringen.

Lineær regresjon peker i samme retning, men med annen fortegning. **Discount** (−166,35) har den største meningsfulle koeffisientverdien; **Region_North**-koeffisienten er isolert sett størst i tallverdi (−277,20), men bygger på én enkelt observasjon (jf. kap. 5.2) og bør tolkes som usikkerhet snarere enn en substansiell regioneffekt. Det negative fortegnet for **Discount** i den lineære modellen står i kontrast til dens høye feature importance i Random Forest, der retningen ikke er fiksert. Det mest sannsynlige er at sammenhengen mellom rabatt og salg er ikke-lineær eller samspillende med andre variabler – for eksempel at rabatteffekten avhenger av produktkategori eller sesong – slik at en lineær spesifisering overkompenserer med ett fortegn mens et tremodellbasert ensemble fanger opp flere betingede mønstre. Forskjellen er derfor ikke motstridende funn, men et tegn på at modellene svarer ulikt på det samme underliggende signalet. Variabelsignalene er prediktive, ikke kausale, og bør tolkes som indikatorer på hvilke dimensjoner som bærer prognoseverdien.

9.3 Teoretiske implikasjoner

Funnene gir et faglig bidrag utover Dagligvare-caset. At gapet mellom tuned Random Forest og benchmark lineær er marginalt på totalnivå (2,13 RMSE-enheter), men tydeligere på månedsnivå og i bestemte segmenter, illustrerer at ensemble-gevinsten er sterkt kontekstavhengig. På datasett med relativt lav strukturell ikke-linearitet, moderat størrelse (~7 700 treningsrader) og dominerende kalender- og rabattsignaler nærmer ensemble-fordelen seg null på samlemålene, mens den slår tydeligere ut når absolutt presisjon (RMSE) prioriteres på finere tidsoppløsning. Dette samsvarer med en generell forventning om at ensemble-metoder krever ikke-lineære interaksjoner og/eller store datamengder for å gi store gevinster — Carbonneau et al. (2008) finner tilsvarende at maskinlæringsmetoder gir tydeligst forbedring der etterspørselsmønsteret er komplekst og dataene er rike. Rapporten bidrar med et empirisk eksempel der disse forutsetningene bare delvis er oppfylt. Sprikende fortegn for **Discount** i lineær versus Random Forest (jf. §9.2) støtter samme tolkning: signalet ser ut til å være ikke-lineært eller betinget, ikke entydig negativt.

9.4 Praktisk nytte for Dagligvare

En MAPE på rundt 44 % er høyt sett opp mot operative benchmarks i varehandel, der prosentavvik under 20 % ofte regnes som brukbart for daglige prognoser. På dagsnivå med høy varians i datasettet (standardavvik 578 på salg med snitt 1 497) er prosentfeilen likevel forventet å være stor, og prosentfeil er per definisjon ustabil når faktiske volum er små (jf. §3.3). Modellens praktiske verdi for Dagligvare ligger derfor mer i den relative rangeringen mellom modellsporene og i segmentanalysen enn i absolutt MAPE-nivå. For operativ innkjøpsbruk anbefales i tillegg aggregering til uke- eller månedsnivå, der enkeltdagers prosentavvik glattes ut.

Funnene har fire tydelige praktiske bruksområder i Dagligvare, alle forankret i modellvalget i 9.1 og variabelrangeringen i 9.2. For innkjøp og overordnet lagerstyring er tuned Random Forest det naturlige standardvalget fordi modellen er best samlet på absolutt presisjon og gir den mest stabile månedsyttelsen. Analysen dokumenterer ikke lageroptimalisering i snever forstand, men

gir et sterkere grunnlag for å treffe bedre på totalnivå i planlagte bestillinger og dermed redusere risiko for både over- og underbestilling.

Tabell 9.2 oppsummerer beslutningsmatrisen med anbefalt modellrolle, prioritert metrikk og hovedforbehold per bruksområde.

Beslutningsområde	Anbefalt modell	Prioritert metrikk	Praktisk nytte	Hovedforbehold
Innkjøp og lager	tuned RF	RMSE	høy	Ikke lageroptimalisering; prosentfeil kan være ujevn i delsegmenter.
Kampanje og rabatt	tuned RF, med baseline RF som MAPE-kontroll ved høy rabatt	RMSE med MAPE-kontroll	middels	Rabattsignalene er prediktive, ikke kausale.
Bemanning og ressursplanlegging	tuned RF, med benchmark lineær-kontroll ved svært høyt salgsnivå	RMSE	middels–høy	Ikke butikk- eller skiftoptimalisering; toppbelastning krever ekstra varsomhet.
Ledelsesrapportering	tuned RF som hovedprognose, benchmark lineær som forklaringsstøtte	RMSE med forklaringsstøtte	middels	Lineær modell skal ikke brukes som kausalt bevis for salgsendringer.

Tabell 9.2 *Beslutningsmatrise og bruksregler: beslutningsområder, anbefalt modellrolle, prioritert metrikk, praktisk nyttegrad og hovedforbehold.*

For kampanje- og rabattvurderinger anbefales tuned Random Forest som hovedmodell, men med en ekstra kontroll mot MAPE i segmentet for høy rabatt, der baseline Random Forest er best på prosentfeil. Dette gjenspeiler at **Discount** er det sterkeste enkeltsignalet i modellen, men at prosentavvik er mer følsomt enn absoluttavvik i rabattutsatte perioder. For aggregert bemannings- og ressursplanlegging gir tuned Random Forest et robust bilde av forventet aktivitetsnivå per måned og kvartal, men benchmark lineær bør trekkes inn når toppbelastning planlegges, siden den er sterkere i segmentet for høyt salgsnivå. For ledelsesrapportering fungerer tuned Random Forest som hovedprognose, mens benchmark lineær brukes som forklaringsstøtte når retningen i sentrale signaler må kommuniseres kortfattet for ikke-tekniske interessenter. I alle disse bruksområdene må analysens avgrensninger holdes eksplisitt: prognosene er prediktive, ikke kausale, og bør kombineres med lokal fagkunnskap før de omsettes til operative beslutninger.

9.5 Metodiske begrensninger

Flere metodiske forhold setter grenser for hvor langt funnene kan strekkes, og de påvirker både påliteligheten innenfor caset og generaliserbarheten utover det. Datagrunnlaget er representativt for caset, men består av ett datasett fra én virksomhet; påliteligheten innenfor caset kan fortsatt være god, mens robustheten mot andre kontekster ikke er testet, og funnene kan ikke uten videre overføres til andre dagligvarekjeder, regioner eller produktmixer uten eget datagrunnlag og ny validering. Analysen inkluderer heller ikke eksterne makroøkonomiske faktorer som inflasjon, rente eller konjunkturer, slik at prognosene kan være mindre robuste dersom 2025 påvirkes av forhold utenfor feature-settet, og resultatene generaliserer dårligere til perioder der slike eksterne sjokk spiller en større rolle. Modellomfanget er dessuten avgrenset til multipl lineær regresjon og Random Forest Regressor; den valgte modellen er best i prosjektets kandidatfelt, men ikke nødvendigvis best mulig totalt sett, og andre metodeklasser – tidsrekkemodeller, gradient

boosting, nevrale nett – er ikke vurdert, noe som gir begrenset grunnlag for å generalisere at samme modellfamilie er best i andre lignende problemer.

De øvrige forholdene gjelder estimering og tolkning. Den lineære modellen brukes med uregularisert OLS på en modellmatrise med 67 features, inkludert mange one-hot-kodede dummyvariabler, noe som gir en betydelig risiko for multikollinearitet; dette svekker tolkningsvaliditeten av de enkelte koeffisientene selv om prediksjonskraften kan være upåvirket, og koeffisientmønstre kan endre seg når datastruktur eller kategorifordeling endres i andre case. Hyperparametertuningen av Random Forest er basert på ett valideringsår (2024), slik at valget av tuned konfigurasjon reflekterer mønstrene i ett år framfor en mer robust kryssvalidering over flere perioder, og sensitiviteten for andre valideringsvinduer er ikke undersøkt. To planendringer i modellutviklingsfasen er dokumentert i endringsloggen: det felles treningssteget ble gjort om til en verifisering av treningsgrunnlag og modellsignaler siden begge modellene allerede var trent i forutgående aktiviteter, og hyperparametertuningen ble avgrenset til Random Forest-sporet alene. Samlet styrket disse endringene sporbarheten i modellutviklingen, men innebærer at lineær regresjon ikke har gjennomgått tilsvarende optimalisering.

Funnene er i tillegg prediktive og ikke kausale. Variabelrangeringer og koeffisienter forteller hvilke signaler som er nyttige for å predikere salg, men ikke hvorfor salget endrer seg, og beslutninger som krever kausal innsikt kan ikke generaliseres direkte fra disse prediktive mønstrene. Denne avgrensningen er viktig å holde fast ved når resultatene oversettes til beslutningsstøtte, for eksempel når rabattsignalet skal tolkes i kampanjearbeidet.

9.6 Videre arbeid

Fire typer videre arbeid følger naturlig av disse begrensningene. Et første steg er supplering med fagfellevurderte kilder innen etterspørselspredikering i dagligvarehandel, som kan styrke både metodevalg og tolkning. Et andre steg er sensitivitetsanalyse av variabelsignalene – særlig **Discount** og regionvariablene – slik at tolkningen blir mer robust mot ikke-lineære sammenhenger. Et tredje steg er bredere validering, enten ved å bruke flere år som valideringsvinduer eller ved å teste modellene mot reelle salgsdata fra en dagligvarekjede. Et fjerde steg er utvidelse av modellomfanget til tidsrekke- og gradient-boosting-metoder som kan adressere både det systematiske høstbias-mønsteret og den heterogene MAPE-ytelsen på en mer presis måte.

10 Konklusjon

Problemstillingen spør hvordan multippel lineær regresjon og Random Forest Regressor kan brukes til å predikere salg i 2025 for en dagligvarekjede, og hvilke faktorer som påvirker salget mest. På tvers av de tre modellsporene er tuned Random Forest det samlet beste valget med RMSE 578,26 og MAPE 43,97% på 2025, og modellen vinner RMSE i elleve av tolv måneder og tretten av fjorten tolkningssegmenter. Gapet til benchmark lineær er likevel marginalt på totalnivå, og sistnevnte er best i segmentet for høyt salgsnivå. Anbefalingen er derfor at Dagligvare bruker tuned Random Forest som standardprognose for innkjøp, lager og aggregert ressursplanlegging, benchmark lineær som forklaringsstøtte og som supplement i toppbelastningssituasjoner, og baseline Random Forest som kontroll mot prosentfeil i perioder med høy rabatt.

Rabatt og kalendervariabler er de mest påvirkningsrike prediktorene, der **Discount** er det sterkeste enkeltsignalet og kalendergruppen samlet står for om lag 42% av importance i topp 10 i den anbefalte modellen. Regionvariablene bidrar som sekundære prediktorer og driver samtidig variasjon i MAPE mellom markedene. Funnene gjelder innenfor dette caset og bør tolkes som prediktive signaler, ikke kausale forklaringer; operativt bruk forutsetter at Dagligvare kombinerer

modellprognosene med lokal fagkunnskap og vurderer supplerende validering før de omsettes til beslutninger i innkjøp, kampanjestyring og ressursplanlegging.

Rapporten bidrar både praktisk og faglig. Praktisk leverer den Dagligvare en konkret beslutningsmatrise for modellvalg på tvers av innkjøp, kampanje, ressursplanlegging og ledelsesrapportering, samt et eksplisitt forbehold om hvilken metrikk som bør prioriteres når. Faglig leverer den en kontrollert empirisk sammenligning av to modellfamilier på ett dagligvarecase med streng tidsbasert oppsplitting, der både samlede mål, månedsnivå, segmentnivå og bias-mønstre er rapportert — og dokumenterer at ensemble-fordelen kan være marginal på totalnivå selv når modellen vinner det store flertallet av månedene og segmentene.

11 Bibliografi

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>

Carbonneau, R., Laframboise, K., & Vahidov, R. (2008). Application of machine learning techniques for supply chain demand forecasting. *European Journal of Operational Research*, 184(3), 1140–1154. <https://doi.org/10.1016/j.ejor.2006.12.004>

Cerqueira, V., Torgo, L., & Mozetič, I. (2020). Evaluating time series forecasting models: An empirical study on performance estimation methods. *Machine Learning*, 109(11), 1997–2028. <https://doi.org/10.1007/s10994-020-05910-7>

Fildes, R., Ma, S., & Kolassa, S. (2022). Retail forecasting: Research and practice. *International Journal of Forecasting*, 38(4), 1283–1318. <https://doi.org/10.1016/j.ijforecast.2019.06.004>

Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting*, 22(4), 679–688. <https://doi.org/10.1016/j.ijforecast.2006.03.001>

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2. utg.). Springer. <https://doi.org/10.1007/978-1-0716-1418-1>

Kang, R. (2023). Sales prediction of Big Mart based on linear regression, random forest, and gradient boosting. *Advances in Economics, Management and Political Sciences*, 17, 200–207. <https://doi.org/10.54254/2754-1169/17/20231094>

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). Statistical and machine learning forecasting methods: Concerns and ways forward. *PLOS ONE*, 13(3), e0194889. <https://doi.org/10.1371/journal.pone.0194889>

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting*, 38(4), 1346–1364. <https://doi.org/10.1016/j.ijforecast.2021.11.013>

Mitra, A., Jain, A., Kishore, A., & Kumar, P. (2022). A comparative study of demand forecasting models for a multi-channel retail company: A novel hybrid machine learning approach. *Operations Research Forum*, 3(4), 58. <https://doi.org/10.1007/s43069-022-00166-4>

Spiliotis, E., Makridakis, S., Semenoglou, A.-A., & Assimakopoulos, V. (2022). Comparison of statistical and machine learning methods for daily SKU demand forecasting. *Operational Research*, 22(3), 3037–3061. <https://doi.org/10.1007/s12351-020-00605-2>

Ulrich, M., Jahnke, H., Langrock, R., Pesch, R., & Senge, R. (2021). Distributional regression for demand forecasting in e-grocery. *European Journal of Operational Research*, 294(3), 831–842.

12 Vedlegg

Dette kapitlet samler referanser til stort eller detaljert datamateriale som ikke er limt direkte inn i rapporten, men som ligger som kildefiler under `006analysis/`. Vedleggene A1–A7 gir leseren direkte tilgang til de underliggende analyseartefaktene.

Tabell 12.1 lister vedleggene A1–A7 med innhold og tilhørende kildefil under `006analysis/`.

Tabell 12.1 Vedleggsreferanser til stort datamateriale som hører til analysen.

Vedlegg	Innhold	Kildefil
A1	Radvised prognoser for 2025 for alle tre modeller (3 312 rader)	tab_prognoser_2025_detalj.csv
A2	Radvised prognosefeil og absoluttfeil for 2025	tab_prognosefeil_2025_detalj.csv
A3	Full tuning-kandidatgrid for Random Forest	tab_rf_tuning_kandidater.csv
A4	Full feature importance for tuned Random Forest	tab_rf_tuned_feature_importance.csv
A5	Full koeffisienttabell for lineær regresjon	tab_lr_koeffisienter.csv
A6	Full RMSE og MAPE per måned i lang form	tab_rmse_mape_maaned.csv
A7	Full segmentmetrikk per modell	tab_segmentmetrikk_modell.csv